

Estadística Aplicada y Manejo de Datos en R

Una Introducción para Ciencias de la Vida y Ciencias Biológicas/Ecológicas

Basado en los principios de: Myra L. Samuels, Jeffrey A. Witmer y Andrew A. Schaffner
Fundamentos de Estadística para las Ciencias de la Vida

Fecha de generación: 9 de julio de 2026

Objetivos del Curso:

1. Comprender el origen histórico de la estadística y el surgimiento de la bioestadística.
2. Conocer el desarrollo temático desde la descriptiva hasta los modelos probabilísticos clásicos.
3. Estructurar y jerarquizar la información científica, desde datos empíricos hasta bases de datos complejas.
4. Manipular y gestionar datos mediante R (data.frame) y Python (Pandas DataFrame).

1 Desarrollo Temático del Curso de Bioestadística

Este curso introductorio está estructurado para proporcionar al estudiante una base conceptual lógica y secuencial, integrando la teoría matemática con el análisis computacional en R.

Módulo I: Fundamentos y Conceptos Iniciales

Definición formal de la estadística y delimitación de la **Bioestadística** como una disciplina con metodologías propias, orientada a modelar la variabilidad inherente en sistemas vivos y ecosistemas.

Módulo II: Estadística Descriptiva

Objetivo: Resumir, organizar y caracterizar un conjunto de observaciones para hacer descriptiva y comprensible la información sin extrapolar aún conclusiones. **Constitución:** Medidas de tendencia central (media, mediana, moda), medidas de dispersión (varianza, desviación estándar, coeficiente de variación, rango, rango intercuartílico), y representaciones visuales (histogramas, boxplots, gráficos de dispersión).

Módulo III: Fundamentos y Principios de Probabilidad

Definición: Teoría matemática que cuantifica la incertidumbre de fenómenos aleatorios. **Temas de estudio:** Espacio muestral, eventos, axiomas de Kolmogorov, probabilidad condicional, independencia y el Teorema de Bayes. **Relevancia actual:** Modelado de transmisión de enfermedades infecciosas, predicción meteorológica, minería de datos y algoritmos de Inteligencia Artificial. **Principios provenientes de la descriptiva:** Las frecuencias relativas observadas en un histograma operan como la aproximación empírica a la función de probabilidad teórica (Ley de los Grandes Números).

Módulo IV: Clasificación y Tipos de Variables

Comprensión del tipo de información recolectada:

- **Variables Discretas:** Valores enteros y aislados, típicos de conteos (ej. número de frutos por planta, células observadas).
- **Variables Continuas:** Valores infinitos no numerables en una escala real, típicos de mediciones físicas (ej. peso, altura, concentración salina, temperatura).

Módulo V: Modelos de Probabilidad y su Relación con las Variables

Explicación de cómo la naturaleza de la variable define el modelo probabilístico:

- **Modelos Discretos:** Gobernados por funciones de masa de probabilidad (PMF), donde cada valor tiene una probabilidad puntual asociada.
- **Modelos Continuos:** Gobernados por funciones de densidad de probabilidad (PDF), donde las probabilidades se evalúan en intervalos (área bajo la curva).

Módulo VI: Modelos de Probabilidad Discreta

- **Distribución Binomial:** Modela la ocurrencia de éxitos en n ensayos independientes con probabilidad fija p .
- **Distribución de Poisson:** Modela la frecuencia de eventos independientes en un continuo de tiempo o espacio, gobernada por una tasa promedio λ .

Módulo VII: Modelos de Distribución Continua: La Distribución Normal

Análisis del modelo continuo de mayor relevancia científica (Campana de Gauss). Estudio de su función de densidad:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$


Identificación de los tres números clave de la matemática que le constituyen: π (Pi), e (número de Euler) y el factor divisor 2 (que define la varianza estandarizada y la simetría). Discusión sobre la importancia de identificar este modelo en la solución de problemas reales mediante el Teorema del Límite Central.

2 Orígenes Históricos de la Estadística y la Bioestadística

La estadística no nació como una disciplina unificada, sino como la convergencia de dos corrientes históricas distintas: la *estadística descriptiva del Estado* (censo, demografía, recuento) y el *cálculo de probabilidades* (nacido de los juegos de azar).

2.1 Cronología del Desarrollo Estadístico

La evolución de esta disciplina puede mapearse a través de hitos fundamentales, desde la simple demografía hasta el desarrollo de lenguajes computacionales especializados.



2.2 El Surgimiento y Definición de la Bioestadística

La **Bioestadística** (denominada en sus inicios como *biometría*) surge a finales del siglo XIX como una especialización científica empujada por la revolución en las ciencias de la vida.

Científicos británicos como **Francis Galton** y **Karl Pearson** se dieron cuenta de que las teorías biológicas de la evolución de Charles Darwin y la herencia de caracteres cuantitativos no podían modelarse mediante las matemáticas rígidas y deterministas de Newton. Requerían un marco matemático que pudiera lidiar con la distribución, la variación, la correlación y la regresión. Posteriormente, **Ronald A. Fisher** formalizó y dotó de rigor matemático el diseño experimental y la genética de poblaciones, creando herramientas indispensables como el análisis de varianza (ANOVA) para experimentos agronómicos.

¿En qué consiste la Bioestadística?

Es la aplicación, adaptación y desarrollo de metodologías estadísticas para el diseño, recopilación, análisis e interpretación de datos empíricos procedentes de las ciencias de la vida, incluyendo la biología, la ecología, la medicina, la agronomía y la salud pública. Consiste en modelar la incertidumbre para comprender los sistemas biológicos bajo una estructura probabilística sólida.

2.3 La Importancia en las Ciencias Biológicas y Ecológicas

¿Por qué la física teórica descansa en ecuaciones diferenciales deterministas mientras que las ciencias de la vida dependen de la estadística inferencial? La respuesta radica en la **variabilidad biológica intrínseca**.

Si medimos la velocidad de caída de una manzana en condiciones de vacío, la gravedad opera de forma idéntica en cada ensayo. Sin embargo, si sembramos dos clones de la planta de maíz (*Zea mays*) en la misma hectárea, bajo idéntico riego y fertilización, las plantas alcanzarán alturas finales distintas. Esta variación proviene de múltiples fuentes indómitas: microclimas del suelo, expresión diferencial de genes, interacciones microbianas e incertidumbre ambiental.

En ecología y biología, la estadística es el lenguaje matemático que permite:

1. Separar el **efecto experimental (la señal)** del **ruido biológico (la variación natural)**.
2. Evaluar patrones espaciales y temporales en comunidades ecológicas (ej., distribución de parches, abundancia de especies).
3. Modelar fenómenos poblacionales sujetos al azar estocástico, como la dinámica de metapoblaciones o el riesgo de extinción de especies amenazadas.

3 Fundamentos Teóricos: De la Descriptiva a los Modelos de Probabilidad

A continuación se detallan los principios científicos de cada módulo para la resolución de problemas y la modelación en investigación.

3.1 Estadística Descriptiva: Objetivos y Constitución

El objetivo de la estadística descriptiva es resumir un gran volumen de información cruda en unos pocos estadísticos o visualizaciones que capturen las propiedades principales del sistema bajo estudio. Se constituye por:

- **Medidas de Tendencia Central:** Indican el centro geométrico o valor central de la muestra (Media aritmética $\bar{x}$, Mediana, Moda).

- **Medidas de Dispersión:** Indican qué tan alejados están los datos respecto al centro (Varianza s^2 , Desviación estándar s , Rango, Rango Intercuartílico IQR).
- **Visualización:** El **Histograma** (que agrupa observaciones en clases y cuenta su frecuencia) y el **Boxplot** o Diagrama de Caja (que expone los cuartiles y destaca los datos atípicos o *outliers*).

3.2 La Probabilidad y su Relación con la Descriptiva

La probabilidad proporciona el fundamento matemático para la estadística inferencial. Mientras que la descriptiva analiza una muestra ya tomada, la probabilidad calcula la certeza de que ocurra un evento futuro dentro de un espacio muestral.

Hoy en día, la probabilidad es crítica para el análisis genético, la estimación del riesgo en salud pública ante nuevas cepas de virus, y la calibración de modelos climáticos predictivos.

Principios Descriptivos como Cimientos de la Probabilidad

El nexo fundamental entre la estadística descriptiva y la probabilidad es el concepto de **frecuencia relativa**.

- En estadística descriptiva, la frecuencia relativa se define como $\frac{\text{frecuencia absoluta del evento}}{n}$ (donde n es el número total de observaciones).
- Según la definición frecuentista de la probabilidad, si repetimos un experimento de forma infinita ($n \rightarrow \infty$), la frecuencia relativa observada convergerá a la probabilidad teórica del evento:

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{veces que ocurre } A}{n}$$

- El histograma de frecuencias relativas es el cimiento descriptivo que prefigura la curva de la **Función de Densidad de Probabilidad (PDF)** en variables continuas.

3.3 Variables y Modelos de Probabilidad

Las variables biológicas se clasifican según su rango de valores posibles:

1. **Variables Discretas:** El rango consiste en valores aislados (conteos). Se modelan con una **Función de Masa de Probabilidad (PMF)**, la cual asigna probabilidades puntuales no nulas a valores específicos: $P(X = x)$.
2. **Variables Continuas:** El rango es un intervalo real continuo. La probabilidad puntual de cualquier valor exacto es cero ($P(X = x) = 0$). En su lugar, se modelan mediante una **Función de Densidad de Probabilidad (PDF)**, donde la probabilidad se define como la integral (el área bajo la curva) en un intervalo específico:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

3.4 Modelos de Probabilidad Discreta

Existen modelos clásicos que describen patrones biológicos frecuentes de variables discretas:

3.4.1. Distribución Binomial

Modela experimentos con únicamente dos resultados posibles (éxito o fracaso, como sobrevivir o morir, sano o enfermo), repetidos n veces de manera independiente con probabilidad constante

de éxito p .

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Uso en Biología: Evaluar la probabilidad de que exactamente 3 de 10 plántulas expuestas a una helada sobrevivan.

3.4.2. Distribución de Poisson

Modela la ocurrencia de eventos raros independientes en un intervalo continuo de tiempo o espacio, caracterizado por una tasa promedio λ .

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Uso en Ecología: Modelar el número de avistamientos de una especie en peligro por cuadrante de muestreo, o mutaciones genéticas en una sección de ADN.

3.5 Modelo de Probabilidad Continua: La Distribución Normal

Es el modelo de probabilidad continua más importante de las ciencias. Frecuentemente denominado "Campana de Gauss", modela variables que resultan de la influencia aditiva de múltiples factores biológicos y ambientales independientes (ej. altura, peso de organismos, presión arterial).

3.5.1. Función de Densidad

La ecuación matemática que define la curva es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Donde μ representa la media aritmética (parámetro de localización central) y σ la desviación estándar (parámetro de escala o dispersión).

3.5.2. Los Tres Números Clave de la Matemática en su Ecuación

La distribución normal es gobernada por tres constantes matemáticas universales que configuran su geometría y simetría:

1. **El Número Pi** ($\pi \approx 3,14159$): Relación entre la circunferencia y el diámetro de un círculo. Aparece bajo la raíz cuádruple en el denominador $\sqrt{2\pi}$ para actuar como una constante de normalización. Asegura que el área total encerrada bajo la campana desde $-\infty$ hasta $+\infty$ sea exactamente igual a 1 , cumpliendo el axioma fundamental de la probabilidad.
2. **El Número de Euler** ($e \approx 2,71828$): Constante natural de crecimiento y decaimiento. Determina la tasa de cambio de la curva normal. Al estar elevado a un exponente cuadrático negativo, genera la suave caída simétrica a ambos lados del pico central (el decaimiento exponencial simétrico).
3. **El Factor Dos** (2): Se presenta dividiendo a la varianza en el exponente ($2\sigma^2$) y como multiplicando de π bajo el radical. Es el factor de escala que normaliza la varianza e impone que los puntos de inflexión de la curva estándar ocurran exactamente a una distancia de una desviación estándar ($\pm 1\sigma$) con respecto al centro μ .

3.5.3. Importancia de su Manejo en la Solución de Problemas

Comprender la distribución normal es de vital importancia por dos razones de peso científico:

- **El Teorema del Límite Central (TLC):** Dictamina que, al extraer muestras grandes de cualquier población (sin importar que la distribución original no sea normal), la distribución de las medias muestrales tenderá a seguir una distribución normal. Esto permite hacer inferencia estadística válida en una inmensa gama de experimentos del mundo real.
- **La Regla Empírica (68-95-99.7):** Facilita la toma de decisiones al saber que en cualquier población normal:
 - El 68.27 % de las observaciones caen a $\pm 1\sigma$ de la media.
 - El 95.45 % caen a $\pm 2\sigma$ de la media.
 - El 99.73 % caen a $\pm 3\sigma$ de la media.
- Permite la **estandarización** o cálculo de valores Z ($Z = \frac{x-\mu}{\sigma}$) para comparar directamente variables medidas en unidades totalmente diferentes.

4 Definición y Jerarquía de Conceptos de Información

Para manejar datos de manera científica y estructurada en software como R o Python, debemos entender los bloques fundamentales de la información desde su expresión más de campo hasta el archivo digital.

4.1 Conceptos Fundamentales

1. Unidad de Información (o Sujeto/Unidad Experimental)

Es la entidad física o abstracta sobre la cual se realiza la medición o la observación.

- *Ejemplo biológico:* Un espécimen de ratón, un cuadrante de suelo de 1m^2 , un árbol en un bosque, o una muestra de sangre de un paciente.

2. Observación (o Caso)

Es el conjunto de todas las mediciones o datos tomados sobre una única **Unidad de Información**. En términos prácticos de almacenamiento, representa un registro completo o una **fila** en una matriz de datos.

3. Dato

Es el valor numérico, categórico o textual que toma una variable en una unidad de información específica. Es la unidad mínima de análisis.

- *Ejemplo:* El valor 25.4 cm para la variable *altura* medido en el árbol número 3.

4.2 Buenas Prácticas en Hojas de Cálculo (Excel)

El archivo de Excel (**.xlsx**) es la herramienta de recolección de datos más extendida. Un **Libro de Excel** se organiza jerárquicamente en **Hojas de Trabajo** (Worksheets).

Estructura Ideal de una Hoja de Datos (*Tidy Data*)

Para que una hoja de Excel pueda ser leída y analizada directamente en R o Python, debe cumplir la norma de la **estructura limpia**:

- **Cada Fila:** Representa una **Observación** única.
- **Cada Columna:** Representa una **Variable** (característica o atributo de la observación).
- **La primera fila:** Contiene exclusivamente los nombres de las variables (encabezados sin espacios ni caracteres especiales).
- **Múltiples Hojas:** Deben utilizarse para separar entidades diferentes (ej., Hoja 1: Metadatos de los sitios; Hoja 2: Muestreo de flora; Hoja 3: Parámetros del agua) en lugar de crear tablas desestructuradas en una misma hoja.

5 El Concepto de Data Frame en R y Python

El **Data Frame** es la representación en memoria ram de la hoja de cálculo bidimensional, permitiendo realizar operaciones vectorizadas masivas.

5.1 Data Frame en R

En el lenguaje R, un `data.frame` es técnicamente una **lista de vectores** de igual longitud. Cada vector corresponde a una columna (variable) y puede tener diferentes tipos de datos (numérico, carácter, lógico o factor), pero todos los elementos de un mismo vector deben ser del mismo tipo.

```

1 # Creacion de un Data Frame en R
2 ecosistema_df <- data.frame(
3   id_arbol = 1:4,
4   especie = c("Quercus robur", "Fagus sylvatica", "Pinus sylvestris", "
      Abies alba"),
5   altura_m = c(18.5, 22.1, 15.3, 24.8),
6   exposicion_sol = c(TRUE, TRUE, FALSE, TRUE)
7 )
8
9 # Inspeccion de la estructura
10 str(ecosistema_df)
11 print(ecosistema_df)

```

Listing 1: Creación e inspección de un Data Frame en R.

5.2 DataFrame en Python (Pandas)

En Python, el objeto nativo no incluye data frames bidimensionales complejos. Se utiliza la biblioteca estándar de facto de ciencia de datos: **Pandas**. En Pandas, un **DataFrame** es una estructura etiquetada de dos dimensiones donde las columnas son objetos de tipo **Series** (vectores indexados).

```

1 import pandas as pd
2
3 # Creacion de un DataFrame en Pandas
4 ecosistema_dict = {
5   "id_arbol": [1, 2, 3, 4],

```


```
6     "especie": ["Quercus robur", "Fagus sylvatica", "Pinus sylvestris",  
7     "Abies alba"],  
8     "altura_m": [18.5, 22.1, 15.3, 24.8],  
9     "exposicion_sol": [True, True, False, True]  
10 }  
11 ecosistema_df = pd.DataFrame(ecosistema_dict)  
12  
13 # Inspeccion de la estructura  
14 print(ecosistema_df.info())  
15 print(ecosistema_df)
```

Listing 2: Creación de un DataFrame en Python usando Pandas.

6 Mapeo Jerárquico y Visualización de la Información

Para comprender cómo interactúan todos estos conceptos, presentamos su jerarquía lógica a través de un esquema relacional y gráfico en la Figura 1.

Figura 1: Mapeo Jerárquico de Conceptos de Información en Ciencias.



6.1 Relaciones de lo Simple a lo Avanzado

1. **Uso Simple (Nivel Físico y de Registro):** El investigador localiza la **Unidad de Información** en el campo, realiza una medición que arroja un **Dato** y registra este dato junto a otros atributos de la misma unidad en una fila de la planilla de campo, conformando una **Observación**.
2. **Uso Intermedio (Nivel de Almacenamiento):** El conjunto de observaciones se digita en una hoja de Excel, donde cada columna representa una variable de estudio. Esto genera una **Tabla**.
3. **Uso Avanzado (Nivel Computacional y Estadístico):** El investigador importa el archivo de datos a R o Python, transformándolo en un **Data Frame**. Mediante esta estructura de datos en memoria, realiza la limpieza lógica, transformaciones matemáticas, modelado estadístico inferencial (como ANOVA o regresiones lineales) y visualización gráfica avanzada (ej., gráficos de dispersión con curvas de tendencia).

7 Conclusión

El manejo científico de la información requiere un entendimiento disciplinado de la jerarquía de los datos. Desde la medición física de una unidad ecológica hasta la manipulación algorítmica de un data frame en R o Pandas, cada paso debe estructurarse rigurosamente. Conocer estos conceptos permite al científico diseñar experimentos válidos, evitar sesgos en el análisis de datos y robustecer la validez de los descubrimientos en las ciencias biológicas.